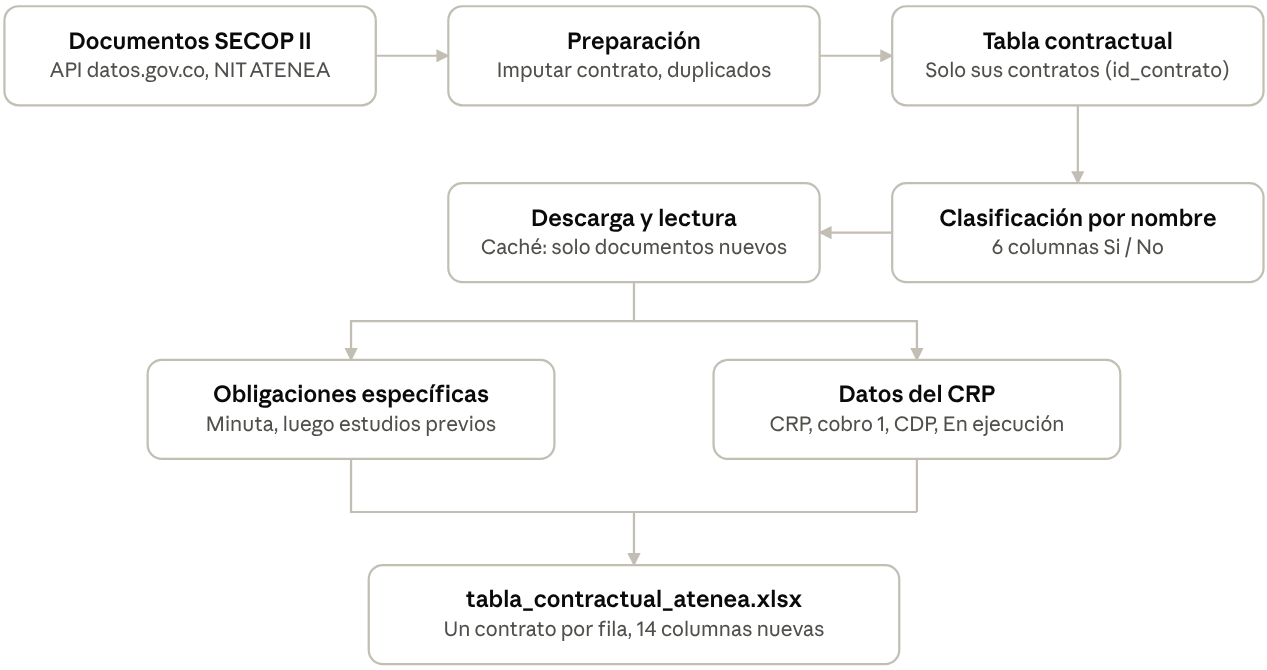
Documentación del proceso — Extracción documental SECOP Atenea

Oct 14, 2026 · @Karen Rojas

Resumen

El notebook **Extracción documental SECOP Atenea.ipynb** toma los documentos contractuales de ATENEA en SECOP II, los clasifica por su nombre, lee los que interesan y extrae las obligaciones específicas y los datos del CRP. El resultado es un solo Excel: la tabla contractual ETL SECOP, una fila por contrato, con las columnas documentales agregadas.

Cada documento se clasifica, se lee una sola vez y completa la tabla contractual



flujo del proceso · de la API a la tabla contractual

Las obligaciones (sección 6) y el CRP (sección 7) se extraen por separado de los documentos ya descargados, y ambos resultados se agregan a la tabla contractual. Las secciones siguientes siguen este orden. La guía de instalación y ejecución está en un documento aparte.

1. Fuentes de datos y preparación (secciones 1 a 4 del notebook)

El proceso parte de dos fuentes: la tabla de documentos contractuales de SECOP II publicada en datos.gov.co y la tabla contractual ETL SECOP (tabla maestra). La tabla contractual es la tabla principal; los documentos se vinculan a ella por número de contrato.

Fuente	Dónde está	Qué se toma
Documentos contractuales SECOP II	API Socrata de datos.gov.co, conjunto `dmgg-8hin`	Solo ATENEA: filtro `nit_entidad = 901508361` aplicado en la consulta
Tabla contractual ETL SECOP ("maestra")	CSV `tabla_maestra_completa.csv` en Oracle Object Storage (bucket `saigc-dl-sandbox`, ruta `analisis_contratacion/gold_exports/tabla_maestra_completa/`)	Todas las columnas; una fila por contrato, llave `id_contrato`

La dirección del CSV de la tabla contractual (`TABLA_CONTRACTUAL_URL`), el token de datos.gov.co (`DATOS_GOV_TOKEN`) y las carpetas de caché y salida se definen en la celda **Configuración general**, al inicio del notebook. Por defecto las carpetas son relativas a la carpeta del notebook (`cache_secop` y la misma carpeta para el Excel).

1.1 Carga desde la API

- Se consulta en bloques de 10.000 filas, ordenadas por el identificador interno `:id`, hasta que la API no devuelve más.
- Se envía el token de la variable de entorno `DATOS_GOV_TOKEN` (encabezado `X-App-Token`), si existe.
- Si el servidor responde 429, 500, 502, 503 o 504, o hay un corte de conexión, se espera (15, 30, 45 s…) y se reintenta hasta 6 veces. Esto se añadió tras un error 500 de datos.gov.co con bloques de 50.000 filas.
- La URL de descarga viene como `{"url": "..."}` y se deja solo el texto.
- Se renombran las columnas a: Número de Contrato, ID Documento, Proceso, Nombre Documento, Tamaño Documento, Extensión, Descripción, Fecha Carga, Entidad, NIT Entidad, URL Descarga Documento.

- Tipos: `Tamaño Documento` a número entero (venía como texto, lo que hacía fallar la regla de tamaño de las minutas) y `Fecha Carga` a fecha.

1.2 Imputación del Número de Contrato

Muchos documentos llegan sin número de contrato pero con el número de proceso. Se completa así:

- Se limpian espacios y los textos vacíos se tratan como vacíos.
- Se cuenta cuántos contratos distintos tiene cada proceso.
- **Solo si el proceso tiene un único contrato**, los documentos sin número de ese proceso reciben ese contrato.
- Si el proceso tiene varios contratos (por ejemplo, un banco de oferentes), no se imputa, porque no se puede saber a cuál corresponde. El notebook lista esos procesos como control.

1.3 Duplicados

Se eliminan las filas idénticas en todas sus columnas.

1.4 Tabla contractual como tabla principal

- La tabla contractual ETL SECOP se carga **tal como viene** (todas sus columnas y filas) y es la única que se exporta. No se hace un cruce documento por documento ni se renombran sus columnas.
- Los documentos de la API quedan en una **tabla de trabajo interna** (`docs`), que no se exporta. Solo se conservan los documentos cuyo `Número de Contrato` está en `id_contrato` de la tabla contractual: los demás (sin contrato o de contratos que no están en la tabla) no se descargan ni se leen, porque no llegarían a la salida. El notebook informa cuántos se omiten.
- De la tabla contractual solo se copian dos datos a cada documento:

Columna en la tabla contractual	Nombre en la tabla de trabajo	Para qué se usa
`año_inferido`	Año	Regla "3XX.pdf" de 2026 (CRP/CDP) y estado de las minutas de 2026 en el log

Columna en la tabla contractual	Nombre en la tabla de trabajo	Para qué se usa
`referencia_del_contrato (contratos_electronicos)`	Referencia del contrato	Identificar el contrato en los logs

2. Reglas de clasificación de documentos (sección 5)

Cada documento se marca con "Si" o "No" en seis columnas según su **nombre** (y en dos casos su tamaño, extensión o año); un mismo documento puede quedar en más de una.

Normalización previa del nombre (no crea columnas): se quitan tildes, se pasa a mayúsculas, los guiones especiales se vuelven "-", el guion bajo se vuelve espacio, los espacios múltiples se reducen a uno y se quitan los espacios alrededor de los guiones ("RP - X" queda "RP-X"). Así "Registro_Presupuestal", "registro presupuestal" y "REGISTRO PRESUPUESTAL" se tratan igual.

2.1 CRP/CDP

Es "Si" si el nombre normalizado cumple cualquiera de estas reglas:

Regla	Ejemplos que cumplen
Contiene la palabra CRP (no dentro de otra palabra)	"CRP sencillo.pdf", "ATENEA-033-2026 CRP.pdf"
Contiene REGISTRO PRESUPUESTAL (con o sin espacio o guion)	"Registro presupuestal 418.pdf"
Contiene "RP " o "RP-" como palabra, excepto cuando va después de "ATENEA-"	"RP adicion.pdf", "RP-413-2026.pdf" (no cumple: "ATENEA-RP-…")
Contiene RCP, RPS o RP2	"RCP 2025.pdf", "RPS.pdf"
Empieza por "3-2024" (cualquier tamaño)	"3-2024-12069_9_CRP.pdf"
Es exactamente "RP.pdf"	"RP.pdf"
Empieza por "3-2026" **y** pesa más de 2.000.000 bytes	"3-2026-443_9.pdf" de 2,3 MB
Es "3XX.pdf" (tres dígitos que empiezan por 3) **y** el contrato es de 2026	"313.pdf", "322.pdf"

2.2 Estudios/documentos previos

Es "Si" si cumple cualquiera de estas reglas. Abreviaturas usadas: separador = espacio, punto, guion, #, dos puntos o °; número = No, No., Nro, N, N°, Num, Número; uno = 1, 01, 001, UNO o I (nunca 10, 11 ni II).

Regla	Ejemplos que cumplen
Contiene PREVIO	"1. ESTUDIOS PREVIOS.pdf", "Documentos previos.zip"
"1" + separador + CARPETA	"1. CARPETA CONTRATO.rar", "01-CARPETA.zip"
CARPETA + 1	"CARPETA 1.zip", "CARPETA01.zip"
Empieza por PAQUETE, PAQ o CARPETA + (número opcional) + uno	"PAQUETE 1 PMO.zip", "Paquete No. 1.zip", "PAQUETE No. 01.zip", "CARPETA NO 01.zip", "CARPETA # 1.zip", "CARPETA I.zip"

Regla	Ejemplos que cumplen
Empieza por PRIMER/PRIMERA/PRIMERO + PAQUETE o CARPETA	"Primer paquete.zip"
Es exactamente "1.zip"	"1.zip"

2.3 Minutas (una por contrato)

1. **Extensión** (aplica a todas las reglas): pdf, docx o doc.
2. **Regla directa**: el nombre contiene MINUTA o empieza por "CONTRATO ATENEA".
3. **Regla complementaria**: empieza por "ATENEA-", no contiene MINUTA ni CRP y pesa entre 200.000 y 800.000 bytes (el tamaño solo aplica a esta regla).
4. **Exclusión de modificaciones**: no son la minuta del contrato y no traen las obligaciones, así que se descartan si el nombre contiene MODIF, TERMINACION, ADICION, PRORROGA, CESION, SUSPENSION, REANUDACION, OTROSI / OTRO SI, ACLARATORI o LIQUIDACION.
5. **Prioridad por contrato**: si el contrato tiene una minuta por la regla directa, se descartan las que solo cumplen la complementaria.
6. **Una sola por contrato**: de las que quedan, se conserva la de `Fecha Carga` más reciente; si empatan, la de `ID Documento` más alto.

2.4 CDP Exc.

Es "Si" si el nombre contiene CDP o DISPONIBILIDAD PRESUPUESTAL (con o sin espacio o guion). Ejemplos: "CDP 456 BO_C8.pdf", "CERTIFICADO-DE-DISPONIBILIDAD-PRESUPUESTAL.pdf".

2.5 CuentaCobro1 (primera cuenta de cobro)

Es "Si" si el nombre tiene CUENTA o CTA (no como parte de "ACTA"), opcionalmente "DE COBRO", opcionalmente un indicador de número (No., N., Nro., N°) y luego el número 1 (1, 01, 001, #1), sin que siga otro dígito; o si empieza por CC001 / CC-001. Ejemplos: "CTA COBRO N.01 ATENEA-205-2025.pdf", "Cuenta de cobro 1 Edgar Arias.pdf", "CUENTA N.001 ATENEA 275-2025.pdf". No cumplen: "Cuenta de cobro 10", "Acta 1".

2.6 contratoEjecucion

Es "Si" si el nombre contiene EN EJECUCION (con espacio, guion o junto). Corresponde a la impresión de la página del contrato en SECOP en estado "En ejecución", por ejemplo "CO1_PCCNTR_7070516_En ejecución.pdf".

3. Extracción de obligaciones específicas (sección 6)

Para cada contrato se arma una sola lista numerada de obligaciones específicas, tomada del primer documento que la tenga, en este orden: la minuta y luego los estudios previos, del más reciente al más antiguo (máximo 3).

3.1 Orden de fuentes

1. **Fase 1, minuta**: el documento marcado en la columna Minutas. Desde 2026 las minutas ya no traen las obligaciones; en esos casos el log muestra "En 2026 las obligaciones específicas ya no se encuentran en las minutas".
2. **Fase 2, estudios previos**: solo para contratos que siguen sin lista. Se prueba el estudio previo más reciente (por `Fecha Carga` y luego `ID Documento`); si no sirve, el siguiente, hasta 3 (`MAX_ESTUDIOS_PREVIOS_POR_CONTRATO`).
3. La lista se agrega a la fila del contrato en la tabla contractual, en la columna `obligaciones_específicas` ("1. …", "2. …", una por línea); en el log, el documento de donde salió queda con Usado = Si. Si supera 32.000 caracteres (límite de una celda de Excel) se recorta.

3.2 Lectura de los archivos

Formato	Cómo se lee
PDF con texto	PyMuPDF, página por página
PDF escaneado o con texto ilegible	OCR con Tesseract en español a 200 dpi, hasta 90 páginas; se detiene cuando la lista ya no crece durante 3 páginas seguidas
Word .docx	python-docx; las viñetas y numeración automática de Word se marcan para separar ítems
Word .doc (antiguo)	No soportado; queda en el log como "formato .doc no soportado"

Formato	Cómo se lee
.zip	Se abre directamente (incluye comprimidos dentro de comprimidos)
.rar y .7z	Se abren con 7-Zip

- Un PDF se considera escaneado si tiene menos de 100 caracteres por página en promedio o si su texto tiene muy pocas palabras reconocibles (fuentes dañadas que salen como símbolos).
- Se quitan encabezados y pies de página: líneas que se repiten en al menos el 30 % de las páginas, "Página X de Y" y números de página sueltos al inicio o final de la página.
- **Dentro de un comprimido** se ordenan los archivos: primero los que se llaman estudio(s) previo(s) (también con el error frecuente "PREVOS"; "FINAL" suma prioridad), luego los demás. Se descartan los que por nombre son análisis del sector o de mercado, CDP, disponibilidad, idoneidad, insuficiencia, inexistencia, matriz de riesgos, anexos, formatos, SARLAFT u hojas de vida.

3.3 Ubicar el título de la sección

Se buscan títulos en cuatro niveles; se usa el primer nivel que produzca una lista.

Nivel	Título buscado	Ejemplos
1	OBLIGACIONES / COMPROMISOS ESPECÍFICOS(AS), tolerando errores de OCR	"OBLIGACIONES ESPECÍFICAS:", "9.3. OBLIGACIONES ESPECÍFICAS POR PARTE DEL OPERADOR", "7.3.4. COMPROMISOS ESPECÍFICOS DE LA UNIVERSIDAD", "COMPRPMISOS ESPECÍFICOS"
2	COMPROMISOS DE / DEL + nombre	"COMPROMISOS DEL ASOCIADO", "COMPROMISOS DE ETB"
3	OBLIGACIONES (A CARGO) DEL / DE LA / POR PARTE DEL + COMODANTE, COMODATARIO, OPERADOR, ASOCIADO, ALIADO, COOPERANTE, ENTIDAD EJECUTORA o ARRENDADOR	"CLÁUSULA SEGUNDA. OBLIGACIONES DEL COMODANTE:"

Nivel	Título buscado	Ejemplos
4 (último recurso)	OBJETIVOS ESPECÍFICOS	"2.1. OBJETIVOS ESPECÍFICOS"

Para aceptar un título:

- **En mayúsculas**: debe estar al inicio de la línea o tras algo corto ("B)", "DÉCIMA. –"); si está en medio de un párrafo es una mención y se ignora.
- **En minúsculas** ("B) Obligaciones específicas del contratista"): debe ir precedido de un enumerador (B), j., 8.3.) o ser una línea corta que empieza con el título.
- **De quién son**: se descartan los títulos cuyo complemento menciona a la AGENCIA, ATENEA, EL CONTRATANTE, LAS PARTES, LOS COOPERANTES, o que son GENERALES, COMUNES, CONJUNTAS o RELACIONADAS. "OBLIGACIONES DE LA ENTIDAD EJECUTORA" sí se acepta.

3.4 Delimitar la sección

La sección va desde el título hasta el primer **corte fuerte** (máximo 700 líneas):

- Otra cláusula o parágrafo (CLÁUSULA, PARÁGRAFO, DÉCIMA…).
- Otro subtítulo de OBLIGACIONES / COMPROMISOS / VALOR / PLAZO / FORMA DE PAGO (por ejemplo "2.4 OBLIGACIONES DE ATENEA:").
- Un subtítulo numerado en mayúsculas ("3. MODALIDAD DE SELECCIÓN").
- Una línea que empieza con "Nota".
- Un numeral suelto ("9.4." o "k.") cuando lo que sigue está en mayúsculas.

Los títulos en mayúsculas **sin numerar** (por ejemplo "PRODUCTOS ESPERADOS" de una tabla dentro de una obligación) son **cortes suaves**: no cierran la sección, solo recortan la obligación en la que aparecen.

3.5 Separar las obligaciones

Se prueban estos formatos de lista, en orden:

1. **Numeración simple**: "1.", "1)", "1-", "1.Realizar" (sin espacio) o "2 apoyar" (sin punto). Puede empezar en 1 o en 2 (cuando el "1." de Word quedó pegado al título) y tolera un número faltante.

2. **Subnumeración** (1.1, 1.2, 2.1 o tres niveles 2.1.1): se usa si da más ítems que la simple. Se conservan solo las "hojas": un numeral con hijos ("2.1 Administración de cartera") es un subtítulo.
3. **Numeración automática de Word** (solo .docx).
4. **Viñetas de PDF**: •, ●, ■, ■, ◦, ➢, ►, ✓ y los símbolos de la fuente Symbol; si no hay, guiones "-" o "–".
5. **Letras**: a), b), c) o a., b., c., en orden.

3.6 Limpieza de cada obligación

- Se corta en el primer título en mayúsculas que haya quedado pegado.
- Se quitan subtítulos intermedios ("Fase 2: Desarrollo", líneas cortas sin punto final tras una línea en blanco, y las que empiezan por FASE, ETAPA, COMPONENTE o LÍNEA).
- Se quitan pies de página de la Agencia: "(601) 6660006", PBX, agenciaatenea.gov.co, "Carrera 10 No. 28", "Línea 195", "Piensa en el medio ambiente antes de imprimir", "COPIA NO CONTROLADA" y la leyenda de tratamiento de datos.
- Se quita un número suelto al final ("… tipo de oferta. 11").
- Se unen las líneas en un solo párrafo y se descartan ítems de 5 caracteres o menos.

3.7 Estados del log

Estado	Significado
ok	Se encontró la lista
no se encontró la sección	El documento se leyó pero no tiene un título reconocible con lista
En 2026 las obligaciones específicas ya no se encuentran en las minutas	Minuta de contrato 2026 sin la sección
PDF escaneado (sin texto)	Escaneado y sin OCR disponible, o el OCR no leyó nada
comprimido sin PDF/Word, sin estudio previo en el comprimido	El comprimido no trae documentos útiles
formato .doc no soportado, extensión X no soportada	Formato que no se puede leer

Estado	Significado
descarga falló (…)	No se pudo descargar; se reintenta en la siguiente ejecución
error al leer (…)	El archivo está dañado o tiene un formato inesperado

4. Extracción de datos del CRP (sección 7)

Para cada contrato se extraen NumeroCRP, NumeroCDP, Rubro, Descripción Rubro, Concepto Gasto, Fondo, Valor CRP, Fecha CRP (dd/mm/aaaa) y CRP Interno BogData. Se recorren cuatro fuentes en cascada y se usa la primera que dé datos.

4.1 Cascada de fuentes

Orden	Fuente (columna)	Qué se busca	Qué aporta
1	CRP directo (CRP/CDP = Si)	Páginas "CERTIFICADO DE REGISTRO PRESUPUESTAL"	Todos los campos
2	Primera cuenta de cobro (CuentaCobro1 = Si)	Se revisan todas las páginas y se toma la del certificado de registro presupuestal	Todos los campos
3	CDP (CDP Exc. = Si)	Páginas "CERTIFICADO DE DISPONIBILIDAD PRESUPUESTAL"	Todo menos NumeroCRP
4	SECOP "En ejecución" (contratoEjecucion = Si)	Secciones "CDP/Vigencias Futuras" y "Compromiso presupuestal de gastos"	Solo NumeroCDP, NumeroCRP y Valor CRP

- Un documento que no trae el certificado buscado (falso positivo de la clasificación) no aporta nada y queda en el log como "no se encontró el certificado".
- **Respaldo "solo CDP"**: si un documento de la fuente 1 o 2 resulta ser un certificado de **disponibilidad** (por ejemplo "CRP_624_ADICION.pdf"), se guarda aparte. Solo se usa si ninguna fuente trae un CRP; entonces el contrato queda con NumeroCDP, valor, fecha

y rubro, NumeroCRP vacío y fuente "CRP (solo CDP)".

4.2 Varios documentos por contrato

- Se leen **todos** los documentos del contrato en la fuente elegida, del más reciente al más antiguo.
- Un mismo CRP subido dos veces cuenta una sola vez (misma combinación de NumeroCRP, NumeroCDP, Rubro y Valor).
- Si hay varios CRP (inicial, adiciones) o varios rubros, se unen en la misma celda con " | ", ordenados por Fecha CRP del más antiguo al más reciente; un valor faltante se muestra como "-".
- Los datos se agregan a la fila del contrato en la tabla contractual (columnas numero_crp a crp_interno_bogdata).
- En "En ejecución" basta con el reporte de SECOP más reciente.
- `VALOR_CRP_COMO_TOTAL = True` cambia la lista de valores por su suma (por defecto está en False).

4.3 Formatos de certificado soportados

Formato	Cómo se reconoce	Reglas de lectura
BogData (Unidad Ejecutora 01)	"Número : 844", tabla RUBRO / DESCRIPCIÓN DEL RUBRO / CONCEPTO DEL GASTO / FONDO / VALOR	NumeroCRP = "Número"; NumeroCDP = "CDP : 519"; un registro por fila de la tabla (varios rubros = varios registros); Fecha = "Bogotá D.C. AGOSTO 04 DE 2026"; CRP Interno BogData = el número de 6 o más dígitos de la línea "Impresión"
BogData con vigencias futuras	Columna adicional VIGENCIA FUTURA	El número se marca con la vigencia, p. ej. "44 (VF 2029)"

Formato	Cómo se reconoce	Reglas de lectura
Fondo Cuenta SEVEN (Unidad Ejecutora 2)	"Número: CRP - FC - 647"	NumeroCRP = "FC-647"; Rubro = código de depósito (D2270027) y su nombre en Descripción; Fondo = "Fondo Cuenta"; NumeroCDP = "CDP Afectado"; valor en formato 81,773,904.00
Fondo Cuenta anterior (2024-2025)	"Número: 502" + "CDP AFECTADO" + "FONDO CUENTA", sin tabla de rubros	NumeroCRP = "FC-502"; valor bajo VALOR; depósito D… o su nombre ("2. CV ATENEA-FFDS VACUNAS"); fecha "a los 31 de enero de 2025"
SECOP "En ejecución"	Bloques "CDP/Vigencias Futuras" y "Compromiso presupuestal de gastos"	NumeroCDP = códigos de tipo CDP; NumeroCRP = cada compromiso "… Presupuestal (CDP)", o "235 (AVF)" si es de vigencia futura; Valor = "Valor compromiso" o, si no hay, "Valor a utilizar" del CDP; incluye la sección de Regalías

4.4 Casos especiales de lectura

- **Fuente dañada**: algunos PDF SEVEN tienen las letras desplazadas a símbolos privados; se corrigen restando el desplazamiento antes de leer.
- **Tabla no detectada**: si PyMuPDF no reconoce la tabla, la fila se reconstruye del texto entre el encabezado VALOR y la línea Total.
- **Escaneados**, con OCR a 300 dpi:
  - Si la página tiene líneas de tabla, cada celda se lee con un OCR propio (más preciso que el de la página completa).
  - Si no tiene líneas, las palabras se asignan a columnas según su posición bajo los encabezados; el límite entre columnas es la mitad del espacio entre sus títulos.
  - Si el OCR de la página no leyó la tabla (encabezados grises), se vuelve a leer solo la franja entre "… así:" y "CDP".

- En Fondo Cuenta escaneado, si falta el depósito, se lee solo la parte izquierda de la franja DEPOSITO.
- Se toleran errores típicos del OCR: "Número ." en lugar de "Número :", el cero en lugar de la letra O en los códigos de rubro.

4.5 Estados del log

Estado	Significado
ok	Se extrajeron datos
no se encontró el certificado	El documento no tiene un certificado legible del tipo buscado
solo CDP (el documento es un certificado de disponibilidad)	Documento llamado CRP o cuenta de cobro que en realidad es un CDP
descarga falló (…), error al leer (…), extensión X no soportada	Igual que en obligaciones

La columna "Fuente usada" del log indica de qué fuente salieron los datos del contrato.

5. Descarga, caché y procesamiento incremental

Cada documento se descarga y se lee una sola vez; el resultado queda guardado en `cache_secop` y las siguientes ejecuciones solo procesan documentos nuevos o pendientes.

5.1 Descarga desde SECOP

- SECOP respondía "403 acceso denegado" a las descargas hechas con la configuración por defecto de Python. Se resolvió con una sesión que se presenta como navegador (User-Agent de Chrome, idioma es-CO y Referer de community.secop.gov.co).
- Máximo 2 descargas en paralelo y 1 segundo de pausa antes de cada una; con más, SECOP bloquea.
- Hasta 3 intentos por documento.
- **Freno de seguridad**: tras 20 respuestas 403 o 429 seguidas, el proceso deja de descargar en esa ejecución (SECOP está bloqueando) y lo informa.

- **Validación del archivo**: se revisan los primeros bytes para confirmar que de verdad es un PDF, ZIP, RAR, 7Z o DOCX, y no una página de error de SECOP guardada con extensión .pdf. Un archivo dañado en el caché se vuelve a descargar.

5.2 Qué se guarda

Archivo en `cache_secop`	Contenido	Llave
`archivos/<ID Documento>.<extensión>`	El documento descargado	ID Documento
`resultados_obligaciones.json`	Lista de obligaciones, estado, archivo leído y versión de reglas	ID Documento
`resultados_crp.json`	Registros de CRP/CDP, estado y versión de reglas	"fuente|ID Documento"

- Los resultados se guardan cada 50 documentos; si el proceso se interrumpe, continúa donde iba.
- Las descargas fallidas no se guardan: se reintentan en la siguiente ejecución.
- `BORRAR_ARCHIVOS_DESCARGADOS = True` borra cada archivo después de leerlo para ahorrar espacio (por defecto False).

5.3 Versiones de reglas

Cuando se mejoran las reglas se sube un número de versión, y los documentos afectados se releen desde `archivos/` sin descargarlos otra vez.

Constante	Versión actual	Qué se relee al subirla
`VERSION_REGLAS_OBLIGACIONES`	7	Solo los documentos sin obligaciones; los que ya tenían lista desde la versión 6 se conservan (`CONSERVAR_CON_RESULTADO_DESDE = 6`)

Constante	Versión actual	Qué se relee al subirla
`VERSION_REGLAS_CRP`	5	Solo los documentos sin datos; los que ya tenían datos desde la versión 4 se conservan (`CONSERVAR_CRP_CON_RESULTADO_DESDE = 4`)

5.4 Qué pasa con documentos nuevos

En cada ejecución se vuelve a traer toda la tabla documental de la API y se clasifica de nuevo; solo se descargan y leen los documentos que no están en el caché.

- Un CRP nuevo (por ejemplo, de una adición) se suma a la lista del contrato, ordenado por fecha.
- Una minuta más reciente pasa a ser la minuta del contrato y se leen sus obligaciones.
- Solo se procesan documentos de contratos que están en la tabla contractual; un contrato nuevo se completa en cuanto aparece tanto en la API como en la tabla contractual.

6. Salida (secciones 8 y 9)

El proceso entrega un solo archivo, `tabla_contractual_atenea.xlsx`, con las fechas en formato dd/mm/aaaa. La tabla de documentos de trabajo no se exporta.

Hoja	Contenido
Tabla contractual	La tabla contractual ETL SECOP **tal como viene** (todas sus columnas y filas, una por contrato) más las 14 columnas documentales
Log obligaciones (opcional)	Un registro por documento leído: Número de Contrato, Referencia del contrato, Año, ID Documento, Nombre Documento, Tipo (Minuta o Estudio previo), Estado, Archivo leído (dentro del comprimido), N° obligaciones, Usado y URL Descarga Documento

Hoja	Contenido
Log CRP (opcional)	Un registro por documento leído: Número de Contrato, Referencia del contrato, Año, ID Documento, Nombre Documento, Fuente, Estado, Registros encontrados, Registros nuevos, URL Descarga Documento y Fuente usada

Las hojas de log se exportan si `EXPORTAR_LOGS = True` (valor por defecto); con `False` el archivo queda solo con la tabla contractual.

6.1 Columnas documentales

Columna nueva	Origen
`crp_cdp`	URL de los documentos con CRP/CDP = Si o CDP Exc. = Si
`estudios_previos`	URL de los documentos con Estudios/documentos previos = Si
`minutas`	URL de la minuta del contrato
`contrato_ejecucion`	URL de los documentos con contratoEjecucion = Si
`obligaciones_específicas`	Lista extraída en la sección 6
`numero_crp`, `numero_cdp`	NumeroCRP, NumeroCDP (sección 7)
`rubro`, `descripción_rubro`, `concepto_gasto`, `fondo`	Rubro, Descripción Rubro, Concepto Gasto, Fondo (sección 7)
`valor_crp`, `fecha_crp`, `crp_interno_bogdata`	Valor CRP, Fecha CRP, CRP Interno BogData (sección 7)

- Varias URL de un contrato van en la misma celda separadas por " | ", sin repetir, de la más antigua a la más reciente.
- Los nombres siguen el formato de la tabla contractual: minúsculas, "_" en lugar de espacios y tildes donde la palabra las lleva.
- Un contrato sin documentos o sin datos extraídos queda con esas columnas vacías.

- Si la celda de la sección 8 se ejecuta otra vez, se reemplazan las columnas documentales; no se duplican.

7. Problemas resueltos durante el desarrollo y limitaciones conocidas

Las reglas se ajustaron con documentos reales de ATENEA: 31 documentos de prueba para obligaciones y 26 para CRP, que se vuelven a verificar en cada cambio para asegurar que lo que ya funcionaba no se dañe.

7.1 Problemas resueltos

Área	Problema encontrado	Solución
Imputación	Procesos con varios contratos recibían un contrato equivocado	Imputar solo cuando el proceso tiene un único contrato
Minutas	Todas salían "No" porque el tamaño venía como texto con comas	Convertir el tamaño a número antes de aplicar la regla
Minutas	Se tomaban minutas de modificación (adiciones, prórrogas…)	Excluirlas por nombre
Carga API	Error 500 de datos.gov.co con bloques de 50.000 filas	Bloques de 10.000 y reintentos automáticos
Descargas	SECOP respondía 403 a todas las descargas	Sesión que se presenta como navegador, 2 descargas en paralelo, pausas y freno tras 20 bloqueos
Descargas	Archivos guardados que eran páginas de error	Validación de los primeros bytes y nueva descarga
Obligaciones	"1.Realizar" sin espacio, "2 apoyar" sin punto, listas que empiezan en 2, "1.10" solo en una línea	Numeración flexible y tolerancia a un número faltante
Obligaciones	Subnumeración 1.1 / 1.2 y tres niveles	Se toman solo las hojas de la numeración

Área	Problema encontrado	Solución
Obligaciones	Títulos en minúscula, COMPROMISOS, OPERADOR, COMODANTE, OBJETIVOS ESPECÍFICOS	Cuatro niveles de título
Obligaciones	"ENTIDAD EJECUTORA" se excluía como si fuera de ATENEA	Ajuste de la lista de exclusiones
Obligaciones	Tablas dentro de una obligación cortaban la lista	Cortes fuertes y suaves
Obligaciones	Pies de página y números de página pegados a los ítems	Limpieza de pies de la Agencia y números sueltos
Obligaciones	Listas con viñetas en lugar de números	Separación por viñetas
Obligaciones	Escaneado de 90 páginas con la lista en la página 43 (el OCR solo leía 40)	OCR hasta 90 páginas con parada temprana
OCR	Tesseract no se encontraba en Windows	Búsqueda en más carpetas y ruta manual `RUTA_TESSDATA_MANUAL`
CRP	PDF con fuente dañada (símbolos)	Corrección del desplazamiento de la fuente u OCR
CRP	OCR de página completa perdía filas o encabezados	OCR por celda y por franja
CRP	"Número ." leído por el OCR en lugar de "Número :"	Expresiones tolerantes
CRP	Formato de Regalías en "En ejecución"	Detección general de CDP y compromisos
CRP	Formato anterior del Fondo Cuenta y documentos "CRP" que eran CDP	Lector nuevo y respaldo "solo CDP"

7.2 Limitaciones conocidas

- **Clasificación solo por nombre**: un documento con un nombre que ninguna regla reconoce no se clasifica ni se lee. Conviene revisar de vez en cuando los contratos que siguen vacíos.
- **Desfase de la API**: un documento cargado en SECOP puede tardar en aparecer en datos.gov.co; se procesa en una ejecución posterior.
- **Cascada del CRP**: si el CRP inicial solo estaba en la cuenta de cobro y después llega un CRP directo (por ejemplo, de una adición), manda la fuente directa y el CRP inicial deja de mostrarse.
- **Word .doc** (formato antiguo) no se lee.
- **OCR**: en escaneados la descripción y el concepto del rubro pueden salir con errores menores de lectura; los números, valores y fechas se verificaron en todas las muestras.
- **Contratos fuera de la tabla contractual**: los documentos de contratos que no están en la tabla contractual ETL SECOP no se descargan ni se leen, y esos contratos no aparecen en `tabla_contractual_atenea.xlsx`.