Guía de instalación y ejecución — Extracción documental SECOP Atenea

Oct 14, 2026 · @Karen Rojas

Qué hace el proceso y qué vas a recibir

El notebook **Extracción documental SECOP Atenea.ipynb** descarga de datos.gov.co los documentos contractuales de ATENEA (NIT 901508361), clasifica los documentos y extrae de ellos las obligaciones específicas y los datos del CRP, y lo agrega como columnas nuevas a la tabla contractual ETL SECOP (la tabla principal, una fila por contrato). Al terminar deja un solo archivo de Excel:

Archivo	Contenido
`tabla_contractual_atenea.xlsx`	Hoja **Tabla contractual**: la tabla contractual ETL SECOP tal como viene (un contrato por fila) con las URL de los documentos clasificados, las obligaciones específicas y los datos del CRP. Hojas **Log obligaciones** y **Log CRP** (qué se leyó de cada documento y con qué resultado), que se pueden quitar con `EXPORTAR_LOGS = False` en la celda de exportación

El proyecto está en el repositorio de GitHub con esta estructura; basta con clonarlo o descargarlo en una carpeta:

```
Extracción documental SECOP Atenea.ipynb
README.md
requirements.txt
.gitignore
cache_secop/
    resultados_obligaciones.json
    resultados_crp.json
docs/
    Guía de instalación y ejecución
    Documentación del proceso
```

- `resultados_obligaciones.json` y `resultados_crp.json` guardan lo que ya se extrajo de cada documento. Con ellos el notebook no vuelve a descargar ni a leer los documentos ya procesados, y la ejecución pasa de horas a minutos.
- La carpeta `cache_secop/archivos/` (los documentos descargados) no está en el repositorio porque pesa demasiado; se crea sola. Solo se necesita si en el futuro cambian las reglas y hay que releer documentos: en ese caso se vuelven a descargar de SECOP.
- Sin los `.json`, el proceso igual funciona, pero la primera ejecución descarga y lee todos los documentos y puede tardar varias horas.

1. Python y Visual Studio Code

Se necesita Python 3.12 (funciona desde 3.9 en adelante) y Visual Studio Code con las extensiones de Python y Jupyter.

Programa	Versión	Dónde se descarga	Notas de instalación
Python	3.12 (mínimo 3.9)	python.org/downloads	En la primera pantalla del instalador marcar **"Add python.exe to PATH"** y luego "Install Now"
Visual Studio Code	La más reciente	code.visualstudio.com	Instalación por defecto
Extensión **Python** (Microsoft)	La más reciente	Dentro de VS Code: menú lateral **Extensiones** (Ctrl+Shift+X) y buscar "Python"	Instalar la publicada por Microsoft
Extensión **Jupyter** (Microsoft)	La más reciente	Igual que la anterior, buscar "Jupyter"	Es la que permite abrir y ejecutar el `.ipynb`

Para comprobar que Python quedó instalado, abrir el **Símbolo del sistema** (tecla Windows, escribir `cmd`, Enter) y ejecutar:

```
python --version
```

Debe responder algo como `Python 3.12.x`. Si dice que no se reconoce el comando, Python no quedó en el PATH: desinstalarlo y volver a instalarlo marcando "Add python.exe to PATH".

2. Entorno virtual y librerías de Python

Las librerías se instalan en un entorno virtual (`.venv`) dentro de la carpeta de trabajo, para no mezclarlas con otros proyectos.

1. Crear la carpeta de trabajo, por ejemplo `C:\Users\<tu_usuario>\Documents\Atenea`, y copiar ahí el notebook y la carpeta `cache_secop`.
2. Abrir VS Code, menú **File > Open Folder** y abrir esa carpeta.
3. Abrir una terminal en VS Code: menú **Terminal > New Terminal**.
4. Crear el entorno virtual:

   ```
   python -m venv .venv
   ```

5. Activarlo:

   ```
   .venv\Scripts\activate
   ```

   Al inicio de la línea de la terminal debe aparecer `(.venv)`. Si Windows responde que la ejecución de scripts está deshabilitada, ejecutar una vez `Set-ExecutionPolicy -Scope CurrentUser RemoteSigned`, responder `S` y repetir este paso.
6. Instalar las librerías:

   ```
   python -m pip install --upgrade pip
   pip install pandas numpy requests openpyxl "pymupdf>=1.24" python-docx
   ipykernel
   ```

7. Abrir el notebook y, arriba a la derecha, en **Select Kernel**, elegir **Python Environments > .venv**.

Librería	Para qué se usa	Versión probada
pandas	Tablas, cruces y exportación	3.0.5
numpy	Cálculos de apoyo	2.5.3

Librería	Para qué se usa	Versión probada
requests	Consultar la API de datos.gov.co y descargar documentos de SECOP	2.34.2
openpyxl	Escribir los archivos de Excel	3.1.5
pymupdf	Leer PDF y hacer OCR de escaneados (mínimo 1.24)	1.28.2
python-docx	Leer documentos de Word (.docx)	1.2.0
ipykernel	Permite a VS Code ejecutar el notebook con el `.venv`	La más reciente

Las demás librerías que usa el código (os, re, json, zipfile, glob, subprocess, etc.) vienen incluidas con Python.

3. Programas externos: Tesseract (OCR) y 7-Zip

Tesseract permite leer PDF escaneados y 7-Zip abrir comprimidos .rar y .7z. Sin ellos el notebook corre, pero esos documentos quedan vacíos.

Tesseract con idioma español

1. Descargar el instalador de Windows de 64 bits (`tesseract-ocr-w64-setup-….exe`) desde github.com/UB-Mannheim/tesseract/wiki.
2. Ejecutarlo. En la pantalla **Choose Components**, desplegar **Additional language data (download)** y marcar **Spanish**.
3. Dejar la carpeta de instalación por defecto: `C:\Program Files\Tesseract-OCR` .
4. Comprobar que exista el archivo `C:\Program Files\Tesseract-OCR\tessdata\spa.traineddata` .

Si Tesseract quedó instalado pero falta `spa.traineddata` :

1. Descargarlo de github.com/tesseract-ocr/tessdata_fast/raw/main/spa.traineddata.
2. Copiarlo en `C:\Program Files\Tesseract-OCR\tessdata` (Windows pide permiso de administrador).
3. Verificar que el nombre sea exactamente `spa.traineddata` , y no `spa (1).traineddata` ni `spa.traineddata.txt` .

Si se instaló en otra carpeta, escribir esa ruta en la celda 6.1 del notebook, en la línea `RUTA_TESSDATA_MANUAL = r"D:\Programas\Tesseract-OCR\tessdata"`.

7-Zip

1. Descargar el instalador de 64 bits desde 7-zip.org.
2. Instalarlo en la carpeta por defecto: `C:\Program Files\7-Zip`. El notebook lo busca ahí automáticamente.

Los .zip se abren sin 7-Zip; solo los .rar y .7z lo necesitan.

4. Configuración general (primera celda de código)

La primera celda de código del notebook, **Configuración general**, reúne todo lo que se puede ajustar; normalmente solo hay que pegar el token.

Variable	Valor que trae	Qué hacer
`DATOS_GOV_TOKEN`	`""` (vacío)	Pegar el App Token de datos.gov.co entre las comillas
`TABLA_CONTRACTUAL_URL`	Dirección del CSV de la tabla contractual ETL SECOP	Nada, salvo que la tabla cambie de lugar
`CARPETA_CACHE`	`"cache_secop"`	Nada: es la carpeta `cache_secop` junto al notebook
`CARPETA_SALIDA`	`"."` (la carpeta del notebook)	Nada, o una carpeta donde se quiera el Excel

El token de datos.gov.co

- Con el token la API responde más rápido y con menos límites; sin él también funciona, pero más lento.
- Se puede usar el token de quien comparte el proceso. Identifica la aplicación ante la API y no da acceso a su cuenta.
- El límite de consultas es por token: si dos personas ejecutan al mismo tiempo con el mismo, se reparten ese cupo, aunque este proceso hace pocas consultas.

- Para crear uno propio (gratis): iniciar sesión en datos.gov.co, ir a **Developer Settings** del perfil y crear un **App Token**.
- Si `DATOS_GOV_TOKEN` se deja vacío, el notebook busca la variable de entorno de Windows del mismo nombre (opcional: `setx DATOS_GOV_TOKEN "token"` en el Símbolo del sistema y reiniciar VS Code).

Al ejecutar la celda debe aparecer `Token cargado: True` y la carpeta de trabajo, que debe ser la carpeta donde está el notebook.

5. Rutas de trabajo

No hay que cambiar rutas: el notebook trabaja en la carpeta donde está guardado, así que funciona igual en cualquier computador.

- El caché se lee y se escribe en `cache_secop`, junto al notebook (como viene en el repositorio).
- El Excel `tabla_contractual_atenea.xlsx` se guarda junto al notebook.
- La primera celda muestra la **carpeta de trabajo**. Si no es la del notebook (por ejemplo, porque VS Code se abrió en otra carpeta), abrir con **File > Open Folder** la carpeta del proyecto y volver a ejecutar.
- Para usar otras carpetas, cambiar `CARPETA_CACHE` o `CARPETA_SALIDA` en la configuración general por una ruta completa, conservando la `r` antes de las comillas: `CARPETA_SALIDA = r"C:\Users\jperez\Documents\Salidas"`.
- Cada persona debe tener su propia copia de `cache_secop`. No conviene que dos ejecuciones escriban a la vez en la misma carpeta, por ejemplo una carpeta sincronizada de OneDrive o SharePoint.

Opcional: `RUTA_TESSDATA_MANUAL`, en la celda 6.1, solo si Tesseract se instaló en otra carpeta (sección 3 de esta guía).

6. Ejecutar y verificar

Con todo lo anterior listo, se ejecuta el notebook completo con **Run All** y, si `cache_secop` vino con los `.json`, termina en minutos.

1. Abrir VS Code en la carpeta de trabajo y abrir **Extracción documental SECOP Atenea.ipynb**.
2. Verificar arriba a la derecha que el kernel sea **.venv**.

3. Clic en **Run All** (o menú de los tres puntos > Run All).
4. Revisar estos mensajes mientras avanza:

Dónde	Mensaje esperado	Si no aparece
Primera celda	`Token cargado: True`	Ver sección 4 (token)
Sección 1	`Descargadas N filas...`	Si dice `El servidor respondió con error... Reintento`, esperar: reintenta solo hasta 6 veces
Celda 6.1	`OCR activo. Idioma español en: C:\Program Files\Tesseract-OCR\tessdata`	Si sale `AVISO: no se encontró Tesseract...`, ver sección 3
Celdas 6.2 y 7.2	`... (N ya procesados antes)` con N casi igual al total	Si N es 0, `CARPETA_CACHE` no apunta a la carpeta correcta (sección 5)
Sección 9	`Archivo exportado: ...tabla_contractual_atenea.xlsx (N contratos)`	Revisar la ruta `ruta` (sección 5) y que el Excel no esté abierto

Tiempos

- Con `cache_secop` completo: solo se descargan y leen los documentos nuevos desde la última ejecución; normalmente minutos.
- Sin `cache_secop`: la primera ejecución descarga y lee todo, y puede tardar varias horas. Los PDF escaneados son lo más lento (1 a 2 minutos cada uno).
- Si se interrumpe (se apaga el equipo, se cierra VS Code), al volver a ejecutar continúa donde iba, porque los resultados se guardan cada 50 documentos.
- La celda **Prueba rápida** de la sección 6 descarga un solo documento y sirve para confirmar que SECOP permite las descargas (debe mostrar HTTP 200).

7. Problemas frecuentes

Problema o mensaje	Causa	Solución
`ModuleNotFoundError: No module named 'pymupdf'` (u otra librería)	El notebook no usa el `.venv` o faltó instalar	Elegir el kernel **.venv** y repetir el paso 6 de la sección 2 con el `.venv` activado
`Token cargado: False`	Variable mal escrita o VS Code no se reinició	Sección 4: revisar el nombre `DATOS_GOV_TOKEN` y cerrar VS Code por completo
`HTTPError: 500 Server Error` en la sección 1	Falla temporal de datos.gov.co	El código reintenta 6 veces; si aún falla, ejecutar de nuevo más tarde
`AVISO: no se encontró Tesseract con idioma español`	Falta Tesseract o `spa.traineddata`	Sección 3; luego reiniciar el kernel (**Restart**)
Comprimidos .rar o .7z con estado de error	Falta 7-Zip	Instalar 7-Zip en `C:\Program Files\7-Zip` (sección 3)
Muchas descargas con `HTTP 403` o `429`	SECOP bloqueó temporalmente por exceso de descargas; el proceso se detiene solo tras 20 seguidas	Esperar una o dos horas y volver a ejecutar; continúa donde iba. No subir `MAX_DESCARGAS_SIMULTANEAS` de 2
`PermissionError` al exportar	El Excel de salida está abierto	Cerrar el Excel y ejecutar solo la celda de la sección 9
`(0 ya procesados antes)` y la ejecución tarda horas	`CARPETA_CACHE` no apunta a la copia de `cache_secop`	Corregir la ruta (sección 5), reiniciar el kernel y ejecutar de nuevo
`KeyError` con columnas de la tabla maestra	Cambió la estructura de la tabla contractual ETL SECOP	Avisar a quien mantiene el proceso con el mensaje completo
Windows no deja activar el `.venv` (scripts deshabilitados)	Política de ejecución de PowerShell	`Set-ExecutionPolicy -Scope CurrentUser RemoteSigned` en la terminal (sección 2, paso 5)

Tras instalar un programa o cambiar una variable de entorno, siempre reiniciar VS Code o, como mínimo, el kernel del notebook.